

RAG 知识增强生成流程详解

1

用户提问

"我是哮喘患者，明天去公园跑步合适吗？"

2

问题理解 - 提取关键信息

用户画像

哮喘患者 (特殊健康需求)

活动场景

户外跑步 (公园环境)

时间维度

明天 (短期预报范围)

关注要素

花粉浓度/空气质量/温湿度/风力

3

多路数据获取 (并行处理)

- 问题向量化 (embedding-v3)
- 语义匹配 Top-K (K=5)

知识库检索路径

检索结果: 天气预警知识 | 生活指数规则 | 活动建议 | 特殊人群健康

天气数据获取路径

- 调用 WeatherService
- 缓存优先策略 (Redis → DB → API)

天气数据: 温度22°C | 湿度65% | AQI:85 | 花粉:高 | 风力:3级

4

Prompt 组装 (上下文注入)

【System Prompt】你是专业气象决策顾问，综合考虑天气条件、空气质量和用户画像...

Context - 用户画像: 哮喘患者, 65%湿度, AQI:85(良), 公园环境, 明天...

Context - 检索到的知识库片段... [片段数量×3]

【User】我是哮喘患者，明天去公园跑步合适吗？

5

LLM 生成回答

通义千问 qwen-plus

文本生成模型 | temperature=0.7 | max_tokens=2000

SSE 流式输出

实时推送回答内容，提升用户体验

6

结果后处理与返回

引用来源标注: 标记知识库来源，增强可信度

日志持久化: 保存交互日志到数据库

响应时间记录: 记录处理耗时，用于性能监控

格式化输出: 统一JSON格式返回前端

尊敬的用户，根据您的情况分析：

建议：明日不适合户外跑步活动

最终输出给用户

- 花粉浓度极高：哮喘患者易诱发过敏反应 [知识库引用]
- 空气质量AQI=85（良）：处于临界值，敏感人群需注意
- 温湿度条件：22°C/65%适宜运动，但花粉风险更大

替代建议：

- 室内健身房或游泳馆进行有氧运动
- 如必须户外，建议佩戴口罩并选择花粉较少时段

[参考来源：医学指南×2, 气象标准×1]